Tibame ETL 實作班 David Chiu 2015/11/07

關於我



- 大數軟體有限公司創辦人
- ■前趨勢科技工程師
- ywchiu.com
- 大數學堂 http://course.largitdata.com/
- 粉絲頁
 https://www.facebook.com/largitdata
- Machine Learning With R Cookbook

https://www.packtpub.com/big-dataand-business-intelligence/machinelearning-r-cookbook

課程資料

- ■所有課程補充資料、投影片皆位於
 - □https://github.com/ywchiu/tibame_etl

應用ETL進行文字探勘

針對商品與品牌進行監控





























監控社群媒體與新聞資料

- ■監控各社群的網路言論
- ■可以設定關鍵字與警示提醒和有新文章

■使用統計報表觀察每天相關文章數量







蘋果, nownews, udn, 中央跟風傳媒 還有 其他財經媒體

每日統計報表

首頁 關鍵字 監控網頁 反向追蹤



資料萃取、轉換與儲存

數據分析的步驟

- 使用不同工具與方法,以從資料中找出有意義的結果
- ■目的在於從資料中找出規律或固定模式
- 幫助從過去的資料,了解業務未來可能碰到的不確定因素 與未來走向

蒐集資料

整理資料

分析資料

資料 ETL 如同做一道佳餚



原始資料

Raw Data



ETL腳本

ETL Script



結構化資料

Tidy Data

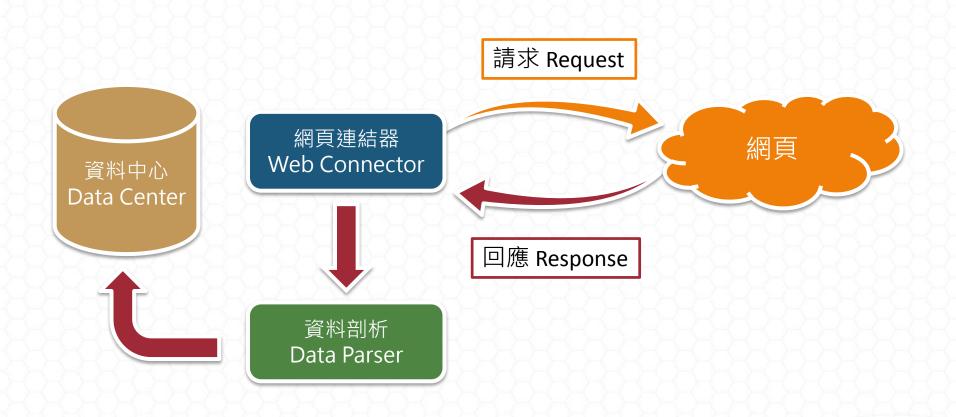
網路爬蟲



將非結構化的網頁資料 轉成結構化資訊

	category	popularity	time	title	url
2	搜奇	0	10:36	歪腰~準岳母跌狗吃屎 美男浪漫求婚成 鬧劇	http://www.appledaily.com.tw/realtimenews/arti
7	國際	5867	10:11	女客乘車遭猥褻 司機竟回「妳沒脫褲怎 進去…	http://www.appledaily.com.tw/realtimenews/arti
9	財經	1293	10:00	【財訊】4個財報密碼 讓你5分鐘嗅出飆 股	http://www.appledaily.com.tw/realtimenews/arti
11	FUN	4640	10:00	路人撿到手機狂拍照 自動上傳讀據讓人 笑了	http://www.appledaily.com.tw/realtimenews/arti
16	政治	4598	09:39	政風處查洩密 徐嵚煌批:本末倒置到極 點!	http://www.appledaily.com.tw/realtimenews/arti
18	社會	51059	09:33	【更新】桃園平鎮兇殺 互砍?他殺?警 方釐…	http://www.appledaily.com.tw/realtimenews/arti
21	生活	29288	09:01	「靠北男友」的洋蔥文 網友淚流不止	http://www.appledaily.com.tw/realtimenews/arti
24	娛樂	2023	09:00	【特企】炎亞綸路跑初體驗獻《蘋果》 雞排	http://www.appledaily.com.tw/realtimenews/arti

網路爬蟲架構



課前預備

- Eclipse
 - https://eclipse.org/downloads/
- Jsoup
 - http://jsoup.org/packages/jsoup-1.8.3.jar
- MySQL
 - https://dev.mysql.com/get/Downloads/MySQLInstaller/mysql-installer-community-5.6.26.0.msi

抓取wikipedia 網頁



Main page Contents Featured content Current events Random article Donate to Wikipedia

Wikipedia store

Interaction

Help

About Wikipedia Community portal

Recent changes Contact page

Tools

What links here Related changes Upload file Special pages Permanent link Page information

Wikidata item

Q Main Page Talk Read View source View history

Welcome to Wikipedia,

the free encyclopedia that anyone can edit. 4.969.903 articles in English

Arts

Biography

Geography

- History Mathematics
- Society
- Technology

Create account . Not logged in Talk Contributions Log in

- Science
- · All portals

From today's featured article



Forrest Highway is a 95-kilometre-long (59 mi) highway in Western Australia's Peel and South West regions, extending Perth's Kwinana Freeway from east of Mandurah down to Bunbury. The highway begins in Ravenswood, continues around

the Peel Inlet to Lake Clifton, and heads south to finish at Bunbury's Eelup Roundabout. Old Coast Road was the original Mandurah-Bunbury route, dating back to the 1840s. Since the 1980s the state government has been upgrading the main Perth to Bunbury route by extending Kwinana Freeway south from Perth, and constructing a dual carriageway on Old Coast Road north of Bunbury, including bypasses around Australind, Dawesville, and Mandurah. Construction of the New Perth Bunbury Highway project, which became Forrest Highway and the final Kwinana Freeway extension, began in December 2006, and the new highway was opened on 20 September 2009. Within one year of opening, the number of road accidents in the area had decreased significantly, but tourism and businesses in the towns on bypassed routes were also affected. In June 2014, Forrest Highway was extended south to Bunbury by renaming much of Old Coast Road as well as Australind Bypass

In the news

- . A magnitude-8.3 earthquake strikes in the Pacific off the coast of Chile, killing at least ten people and prompting the evacuation of at least one million others.
- Burkina Faso's Regiment of Presidential Security dissolves the nation's government in a coup

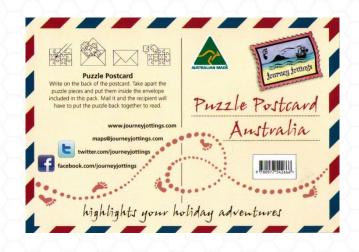


Malcolm Turnbul

- Malcolm Turnbull (pictured) becomes Prime Minister of Australia after replacing Tony Abbott as the Liberal Party leader.
- An explosion in Petlawad, Madhya Pradesh, India, kills more than one hundred people and injures many more.
- . The ruling People's Action Party, led by Lee Hsien Loong, retains its majority in the Singaporean general election.

Ongoing events: European migrant crisis Recent deaths: Moses Malone - Adrian Frutiger

什麼是GET?



GET 內容寫在上頭

http://en.wikipedia.org

使用Jsoup 做 get

```
Document doc;
doc = Jsoup.connect("http://en.wikipedia.org/").get();
String html = doc.html();

System.out.println(html);
```

以台灣高鐵為例



什麼是POST?

StartStation:

977abb69-413a-4ccf-a109-0272c24fd490

EndStation:

fbd828d8-b1da-4b06-a3bd-680cdca4d2cd

SearchDate:

2015/04/19

SearchTime:

17:30

SearchWay:

DepartureInMandarin

John Q. Sample
123 Any Street
Any City, US 12345

POST 內容寫在信紙·包在信封內

https://www.thsrc.com.tw/tw/TimeTable/SearchResult

使用Jsoup 做post

```
Document doc;

doc = Jsoup.connect("http://www.thsrc.com.tw/tw/TimeTable/SearchResult")

.data("StartStation", "977abb69-413a-4ccf-a109-0272c24fd490")

.data("EndStation", "60831846-f0e4-47f6-9b5b-46323ebdcef7")

.data("SearchDate", "2014/06/18")

.data("SearchTime", "10:30")

.data("SearchWay", "DepartureInMandarin")

.post();

String html = doc.html();

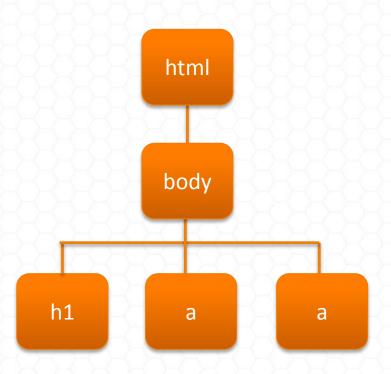
System.out.println(html);
```

任務一如何透過JSoup取得蘋果新聞網頁



DOM Tree

```
<html>
<body>
<h1 id="title">Hello World</h1>
<a href="#" class="link">This is link1</a>
<a href="# link2" class="link">This is link2</a>
</body>
</html>
Document Object Model
```



剖析範例

■ 將網頁讀進JSoup 中

```
Document doc;

doc =

Jsoup.connect("http://en.wikipedia.org/").get();

String title = doc.select("h1").text();

System.out.println(title);
```

尋找CSS 的定位

- Chrome 開發人員工具
- Firefox 開發人員工具

- InfoLite
 - https://chrome.google.com/webstore/detail/infolite/ipjb adabbpedegielkhgpiekdlmfpgal

任務二 如何透過JSoup取得蘋果新聞網頁

www.appledaily.com.tw/realtimenews/section/new/1 使用requests.get 取得頁面內容 2015 / 05 / 25 吳樂最 ĦΟῖ 23:00 中國明發布 軍事戰略白皮書(0) 余苑綺 大姊哈菸陪放風 病... 65686 22:57 財經 美元強強滾! 油價續游走60美元之下(24) 布裘新婚告急吵不停 解危凍... 40514 22:50 打擊登革熱 中國釋放50萬隻絕育蚊(797) Jolin美人魚360度發... 22:44 娯樂 【更新】Jolin安室合體高潮2分10秒...(79730) 阿妹靜悄悄扳台 選鐵粉嚇一... 22:39 全球市佔率前十大啤酒 中國佔4名(1506) 白家綺辣玩纖繩滑水 好身材... 36500 22:39 財經 柏南克今抵台 明專題演講與彭淮南、張忠謀...(18) 22:23 生活 豪爾造成農業損失617萬元 (510) 蘋果粉絲團 蘋果日報 💿 社會 【更新】新商場偷穀基地台 埔里居民抗議(5682) 22:15 政治 【公庫】拒絕修憲議題綁架 國民黨自打嘴...(863) 社會 【更新】驚!休旅車竄出大火 車上2人燙傷...(24129) 政治 22:14 藍遊說選立委 阿姆: 熱愛新聞捨不得改變(6506) 這裡面,你喝過哪些呢?我還是喜歡 台灣製的啤酒 生活 【更新】七車連環撞 中山高大打結(8834) 飲酒過量,有害健康、傷害感情) 社會 22:12 【公庫】RCA受害勞工 使用開發者工具檢視每則新聞的分隔 22:11 國道七隊偵查佐涉賭遭 發現都以.rtddt做分隔 「八字】 /次98.354.88 L //h

http://www.appledaily.com.tw/realtimenews/section/new/

正規表達式

```
String patternStr = "(.+)\((\d+)\)";
Pattern pattern = Pattern.compile(patternStr);
Matcher matcher = pattern.matcher(popularity);
boolean matchFound = matcher.find();
if (matchFound) {
System.out.println(title + "" +
Integer.parseInt(matcher.group(2)));
```

任務三使用正規表達式取得瀏覽人氣



轉換日期資訊

```
String dateStr = "2015-08-26";
SimpleDateFormat formatter = new
SimpleDateFormat("yyyy-MM-dd");
Date dt = formatter.parse(dateStr);
```

或使用JODA 做轉換

```
import org.joda.time.DateTime;
import org.joda.time.format.DateTimeFormat;
import org.joda.time.format.DateTimeFormatter;
DateTimeFormatter fmt =
DateTimeFormat.forPattern("yyyy年MM月dd日
HH:mm");
DateTime dt = DateTime.parse(time, fmt);
System.out.println(dt.toDate().getTime());
```

https://github.com/JodaOrg/joda-time/releases

任務四 轉換日期資訊



任務五 抓取每日新聞摘要

連環撞 中山 高大打結 (4822)

20150525 21:41 北市府同意 遠雄 七月底前完成大巨 蛋大底(8991)

20150525 21:21

入夜雨勢再起 屏 東西大武山雨量 441毫米(3148)

20150525 21:07

【蝦毀?】煙囪 雲覆蓋 中南 ■ 部大雨不停 (8765)

20150525 21:06

【晴雨娃】鋒面徘徊 南部及山區嚴防蒙爾(2529)

20150525 20:55

【BRT達規?】 BRT到發車站前走 在一般道路(2461)

20150525 20:52

5月25日台灣彩券 開獎號碼(2660) (更新:新增影片)

天雨路滑,交通事故也頻傳。國道一號北上高雄鼎金 交流道上午就傳出一起七車連環撞的交通事故,造成 北上車道大打結,車流一直回堵到接近九公里外的國 道末端,直到一小時後警方將事故排除,才逐漸緩解 車流。

國道五隊岡山分隊分隊長葉斌偉表示,上午9時40分 左右國道一號北上鼎金系統交流道發生一起七車追撞 事故,一輔小貨車行駛至中山高北上363.3公里處, 鼎金系統交流道匯出國10閘道口附近時,疑因天雨路 滑車主又急煞導致車輔打滑失控,打橫在車道上的小 貨車遭後方車輔追撞,而事故後後方一輔聯結車又剎 車不及,連續推撞前方車輔,導致七車連環事故。

葉斌偉說,該起事故雖未造成人員受傷,但整起車禍 位於國道一號匯往國道十號閘道口,導致後方欲前往 旗山及左營等方向車流回堵,國道警方於上午10時許 接獲報案後,直到上午10時48分後將事故排除,國 一北上路段塞車狀況才獲得紓解。(劉智維/高雄報 導)

出版時間:17:56 更新時間:22:13





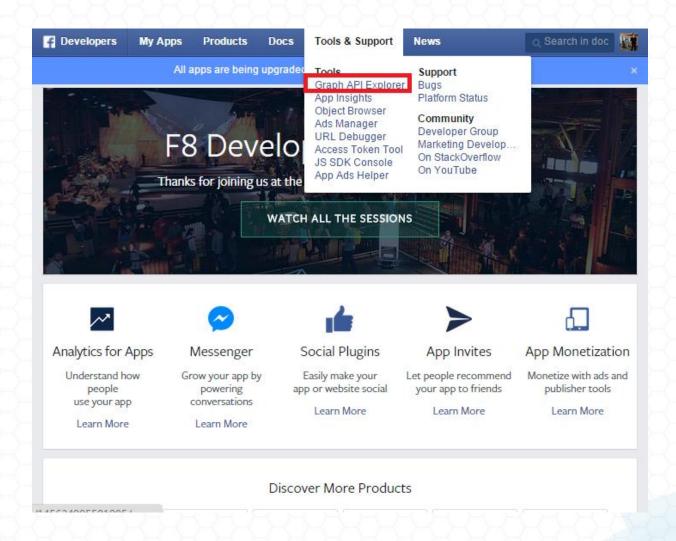
任務六 建立新聞資料表

- ■表格名稱
 - □news_main
- ■欄位名稱
 - □id
 - **□** title
 - **□** content
 - □time
 - □view_cnt
 - category

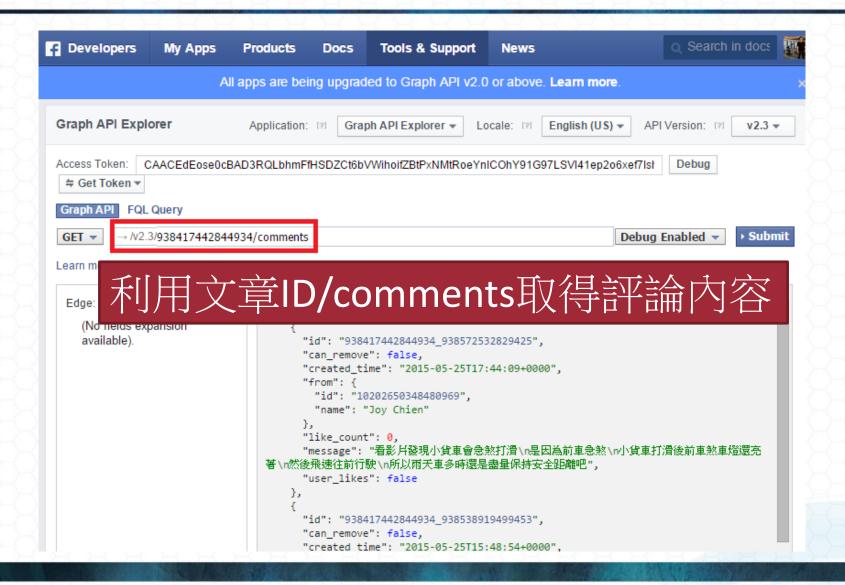
```
CREATE TABLE `news_main` (
  `id` int(11) NOT NULL AUTO_INCREMENT,
  `title` varchar(1000) DEFAULT NULL,
  `content` text,
  `time` datetime DEFAULT NULL,
  `view_cnt` int(11) DEFAULT NULL,
  `category` varchar(10) DEFAULT NULL,
  PRIMARY KEY (`id`)
) ENGINE=InnoDB DEFAULT CHARSET=utf8;
```

如何抓取留言資訊

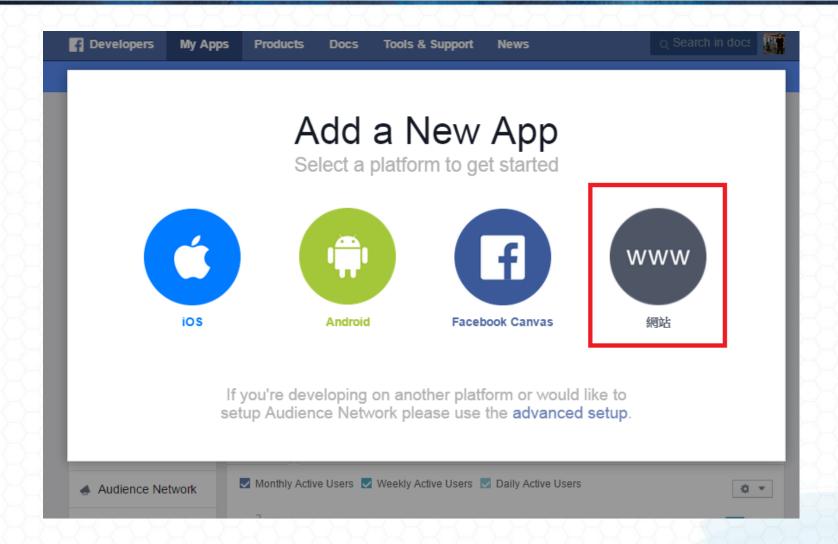
使用Graph API Explorer



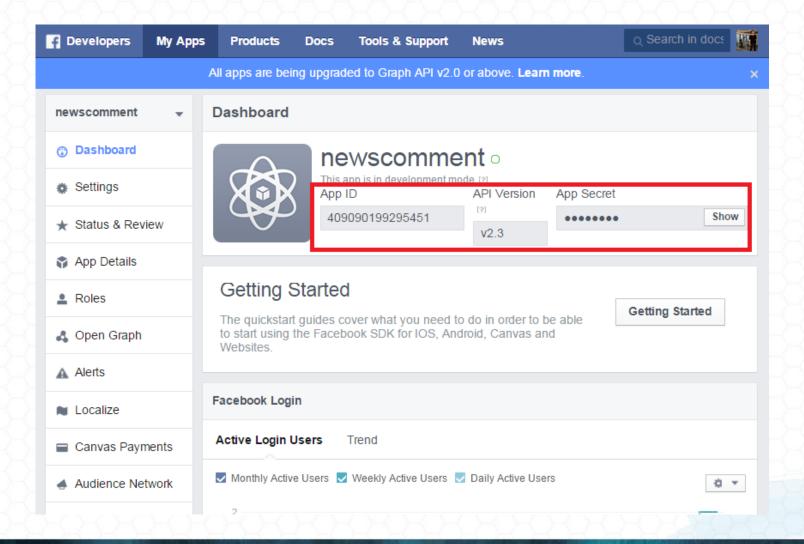
擷取評論



新增一個App

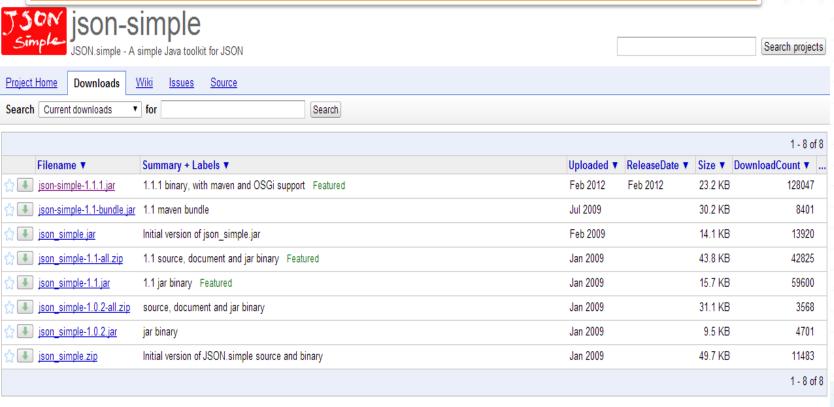


取得APP ID 跟 Secret



json-simple

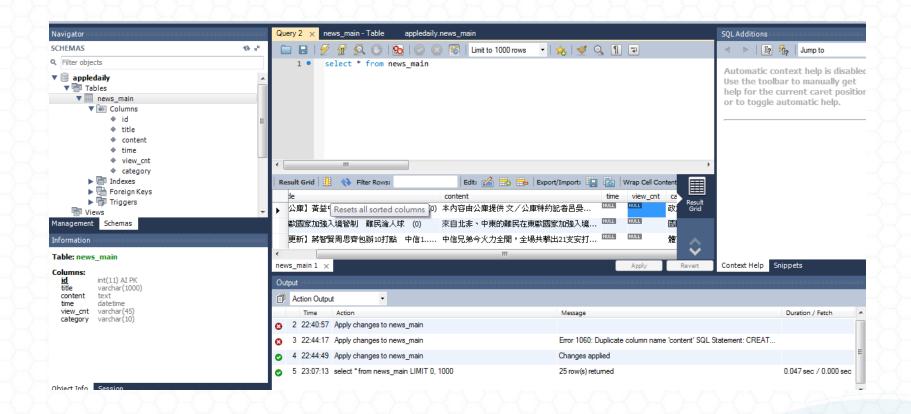
https://json-simple.googlecode.com/files/json-simple-1.1.1.jar



使用json-simple讀取json資訊

```
JSONParser parser = new JSONParser();
Object obj = parser.parse(doc);
JSONObject jsonObject = (JSONObject) obj;
JSONArray dt = (JSONArray)
jsonObject.get("data");
```

使用SQL Wordbench瀏覽資料庫



任務七分析各分類最熱門文章

	category	popularity	time	title	url
3	生活	0	00:27	美妝即期品開賣 每人只能買2件	http://www.appledaily.com.tw/realtimenews/arti
12	社會	22141	00:21	【囂張】柯P地盤近百黑衣人砸服飾店	http://www.appledaily.com.tw/realtimenews/arti
16	體育	23	00:17	台灣一哥盧彥勳法網首戰 周二下午5點 FO	http://www.appledaily.com.tw/realtimenews/arti
19	動物	696	00:14	獵殺老犀牛 是為了防止犀牛絕種?	http://www.appledaily.com.tw/realtimenews/arti
24	娛樂	3442	00:10	【狗仔偷拍】安室缺席Jolin慶功宴 獨	http://www.appledaily.com.tw/realtimenews/arti

聯絡方式

- Website:
 - □ywchiu.com
- Email:
 - ■tr.ywchiu@gmail.com

THANK YOU